

1 Qual'è la relazione tra X-Path e X-Query [XML markup di dati semi strutturali]

XPath navigare file ~~XML~~ ^{tra i} specifici nodi dei file
+ usato con altre tecnologie XML, come XSLT

BASATO
↓

XQuery estrae e manipola dati di file XML
+ stessa sintassi di XPath con cicli e condizioni, crea/edita file

2 Perché passare da MODELLI BOOLEANI a MODELLI VETTORIALI in IR?

- | | | |
|------------------------------------|--|--|
| 1 <u>ORDINAMENTO per RILEVANZA</u> | posso cercare i dati
↓
RISPETTA LA QUERY? $\begin{matrix} \checkmark \\ \times \end{matrix}$
<u>conformità</u> | calcolo <u>SIMILARITA'</u> $\Rightarrow$ <u>ordino i documenti</u>
tra Query & Doc
<u>valori continui</u> |
| 2 <u>FLESSIBILITA' delle QUERY</u> | OPERATORI LOGICI
$\hookrightarrow$ poco intuitivi | Query simili al <u>LINGUAGGIO NATURALE</u>
$\hookrightarrow$ <u>frasi e key</u> $\Rightarrow$ recuperare doc in base alla <u>SIMILARITA'</u> |
| 3 <u>PESO dei TERMINI</u> | hanno tutti lo stesso
↓
non c'è correlazione del valore che ha il contenuto del documento | <ul style="list-style-type: none">• <u>FREQUENZA dei TERMINI</u> (TF)
$\sim$ = quanto poco compare un termine• <u>FREQUENZA INVERSA del DOCUMENTO</u> (IDF) $\times$ rappre l'import dei termini in un doc
$\Rightarrow$ <u>MIGLIORA QUALITA' di RECUPERO</u> |
| 4 <u>MATCHING PARZIALE</u> | <u>CORRISPONDENZA ESATTA</u>
tra Query e Docs | <u>CORRISPONDENZA PARZIALE</u>
$\hookrightarrow$ possono essere <u>RECUPERATI E ORDINATI</u> $\times$ rilevanza
$\Rightarrow$ + ROBUSTO - ha un margine d'errore |
| 5 <u>SINONIMI e POLISEMIA</u> | non associa parole $\neq$
allo stesso <u>significato</u>
↓
specificarle <u>TUTTE</u> le variazioni
<u>solo PERFECT-MATCH</u> | $\checkmark$ Relazioni semantiche tra le parole
$\uparrow$ CATTURARE CONCETTI LATENTI
$\uparrow$ word embedding models |

3 Eventi, Misure e Dimensioni nel Data Warehouse

FATTO evento che accade che voglio analizzare → domanda 14

MISURE valori numerici ASSOCIATI a un fatto → su cui fare ANALISI / AGGREGAZIONI

DIMENSIONI descrivere il CONTESTO del fatto

ES: fatto = vendita

misura = importo

dimensioni = { tempo, prodotto, luogo }

↳ ADATTIVE (+ a tutte le Dim)

↳ SEMI ADATTIVE (+ a alcune Dim)

↳ NON ADATTIVE (≠ a Dim)

↳ DISTRIBUITE (fun di aggregazione in modo distribuito)

↳ ALGEBRICHE (" " " = fun scalare) media

↳ OLISTICHE (non possono essere calcolati da altri sotto aggregati) medie

4 Cosa sono PRECISIONE e RECALL in IR ?

PRECISIONE % di documenti RECUPERATI che sono RILEVANTI

RECALL % di documenti RILEVANTI TOTALI che il sistema è riuscito a RILEVARE
→ ha trovato tutto quello che doveva trovare

5 Differenza tra XML Schema e DTD

DTD - Document Type Definition

- specifica ELEMENTI e ATTRIBUTI che sono ammessi e in che ordine in file XML

XML Schema → mi dà una convenzione e delle regole

- DTD + supporto a tipi di dato e i loro LIMITI di CONTENUTO
- Supporta intervallo e pattern
- Scritto in XML

+ espressivo di DTD

REGOLE SINTATTICHE XML

1. elementi in TAG
<a> ,
2. TAG stesso nome
3. attributi del TAG con " "
4. doc inizia con PROLOGO
~~XML Schema + DTD~~ DOCTYPE
5. commenti <!-- -->

file XML con DTD | XML Schema = valid e well-formed ↑

file XML = well-formed ≡ rispetta le regole sintattiche di XML

come lo uso nei database ? (XML Schema)

↳ so come è definito ⇒ uso Query specifiche usando le regole

⇓
migliore gestione e organizzazione dei doc XML

6 Differenze tra Data Warehousing e Data Mining

DATA WAREHOUSING = RACCOLTA / INTEGRAZIONE / ORGANIZZAZIONE di grandi quantità di dati storici x Supportare il processo decisionale

↓
usa FATTI / MIS / DIM
x avere analisi più mirate

DATA MINING = processo di analisi dati x ESTRARRE pattern / relazioni / informazioni con tecniche STATISTICHE e di ML
x migliorare comprensione dei dati

7 Che problemi ci sono se un linguaggio simil-XQuery venisse applicato ai grafi

XQuery → XML • Struttura ad ALBERO ACICULO → 1 cammino tra RADICE e NODO

1 Grafi possono avere CICLI e + CAMMINI TRA STESSI NODI

XQuery: NAVIGAZIONE FINITA e DETERMINISTICA

Grafi: NAVIGAZIONE NON FINITA o produce DUPLICATI (se non si specificano sistemi di controllo dei CICLI)

2 Grafi hanno RELAZIONI più generali vs padre-figlio/fratello di XML

XQuery - non ha - tipi di archi diversi

- direzioni
- vincoli complessi

} x non esprimibili in modello ad ALBERO

3 navigazione per cammini + complessa nei Grafi

↳ lunghezza arbitraria v condizioni sulla Struttura ⇒ XQuery ha bisogno di OPERATORI + POTENTI

↳ chiusura transitiva

8 Problema: unire information retrieval TEMPORALE e SPAZIALE

Sono 2 dimensioni aggiuntive: TEMPO = validità e decadimento della rilevanza con NATURE DIVERSE

SPAZIO = distanze e relazioni geografiche

↓
o difficile creare un'unica FUNZIONE di RANKING → con RILEVANZA testuale

ARCHITETTURA

COMPUTAZIONE

o IR: usa indici testuali vs strutture indici diverse ⇒ Query MULTIDIMENSIONALI e + COSTOSE

o RILEVANZA cambia nel tempo e spazio ⇒ difficile valutare con metriche standard
PRECISION e RECALL

9 Differenze tra Data Warehouse e Database

DATABASE = progettato x supportare **APPLICAZIONI OPERATIVE**

sono NORMALIZZATI

x - Ridondanza

x Coerenza

con Query mirate e specifiche

x efficienza
x correttezza

gestire DATI CORRENTI
↓
che cambiano dinamicamente

DATA WAREHOUSE = progettato x ANALISI e DECISIONI

≡ RACCOLGUE / INTEGRA / ORGANIZZA grandi quantità di dati storici

x Query complesse ← DENORMALIZZATI

10 Perché è stato introdotto il VECTOR SPACE MODEL (o Modello Vettoriale)

Modello booleano : verifica se i documenti / dati corrispondono alle Query o no

↓
RIGIDO ⇒ EXACT-MATCH

Modello vettoriale : cercare documenti per RILEVANZA con le Query

> rileva l'importanza relativa dei termini

> riesce a rilevare Relazioni Semantiche

11 Differenze tra SQL/XML e XQuery

SQL/XML = estensioni di SQL x PRODURRE / INTERROGARE / MANIPOLARE dati XML

IN → dati RELAZIONALI → ~~DB~~ → dati (alberi) XML

XQuery = nativo x XML x MANIPOLARE dati e file XML ⇒ accedere a dati SEMI-STRUTTURATI

12 ETL nel Data Warehouse

Extract Transform Load processo x popolare un DATA WAREHOUSE da sorgenti dati eterogenee

1 **EXTRACT** dati dalle sorgenti

2 **TRASFORMAZIONE** e PULIZIA dei DATI (no INCONSISTENZE + UNIFORMATI) ⇒ formato valido x Data Warehouse

3 **LOADING** caricamento dati nel Data Warehouse

> in modo INCREMENTALE

> aggiorna dati SENZA SCRIVERLI

Garantisce QUALITÀ / COERENZA / STORICIZZAZIONE dei dati analizzati

13 Gestione dati nel Data Warehouse

« Sono memorizzati x Sempre? NO → POLITICHE di RETENTION: per quanto tempo i dati restano disponibili

PROBLEMI di SPAZIO - ARCHIVIAZIONE di dati vecchi su storage meno costosi

- RIDUZIONE LIVELLO di DETAGLIO dati aggregati togliendo dettagli fine

- PARTIZIONAMENTO TEMPORALE
SCALABILITA' ORIZZONTALE distribuire dati su più nodi o sistemi

14 Cos'è un FATTO in un Data Warehouse

EVENTO MISURABILE che si vuole analizzare

memorizzato in una fact table: 1 tupla x evento

sono il punto centrale dello schema a stella / fiocco → x operazione dati

15 Temporal Page Rank = estensione del Page Rank con dimensione temporale del grafo

« l'importanza dei nodi e collegamenti può variare nel tempo » ⇒ da AUTORITÀ

↳ + alta x nodi RECENTI

1 DECADIMENTO TEMPORALE dei LINK

togliere importanza a LINK VECCHI → contribuisce meno all'autorità corrente di una pagina

2 TELETRASPORTO DIPENDENTE dal TEMPO → si interviene nella fase di TELETRASPORTO di PageRank

saltare su un nodo con PAGINE RECENTI / ATTIVE ⇒ Autorità verso contenuti attuali

3 GRAFI DINAMICI = sequenza di grafi nel tempo

snapshot temporali su relazioni recenti (solo) ⇒ Ranking aggiornato periodicamente

« streaming » dati con forti variazioni temporali Seguendo l'evoluzione del grafo

16 Analogie tra Text-mining e Data Mining [hanno ≠ tipi di dato]

« sono processi di analisi e estrazione da grandi quantità di dati

↳ individuare pattern / correlazioni / trend / modelli

« processo simile: raccolta dati → pre-processing → trasformazione → algoritmi di mining → interpretazione → valutazione

« metodi e algoritmi simili: text-mining: trasformo il testo in un formato STRUTTURATO

↓
posso trattarlo come dato

↓
posso usare le stesse tecniche di Data Mining

NOT ONLY SQL

17 NoSQL - cos'è e quali caratteristiche hanno

superare il modello SQL
relazionale $\Rightarrow$ superare ACID
 $\uparrow$

= sistema non relazionale per gestire grandi quantità di dati eterogenei

- Strutturato con key-value
documenti
colonne
grafi
- } x garantire **FLESSIBILITÀ**

x applicativi web / big data / sistemi ad alta concorrenza

- progettati x ambienti DISTRIBUITI $\Rightarrow$ x garantire la **SCALABILITÀ**
(e TOLLERANZA ai GUASTI)

$\downarrow$
PRINCIPIO BASE (BASICALLY AVAILABLE
SOFT STATE
EVENTUALLY CONSISTENT)

18 Quali PROPRIETÀ ci sono in un database SQL che non ci sono in un database NOSQL

- proprietà ACID
ATOMICA
CONSISTENZA
ISOLAMENTO
DURABILITÀ
- $\Rightarrow$ x garantire db passa tra stati in modo CONSISTENTE
NOSQL: difficile garantirlo in ambienti distribuiti

- Schema RIGIDO e DICHIARATIVO $\rightarrow$ con VINCOLI di INTEGRITÀ
- NOSQL: assente o flessibile con delegati all'applicazione**
- } chiavi primarie
chiavi esterne
vincoli di dominio

- linguaggio dichiarativo standard (SQL)

> query complesse > operazioni di aggregazione
> join arbitrari

NOSQL: specifico del sistema e con capacità limitate

- CONSISTENZA forte e IMMEDIATA su un singolo db

NOSQL: consistenza EVENTUALE = accetta repliche che possono divergere nel tempo

x DISPONIBILITÀ

x SCALABILITÀ

19 Vantaggio di estendere SQL con SQL/XML invece di usare macro per SQL

- L'integrazione è PARTE FORNITA del linguaggio e del DBMS $\Rightarrow$ ottimizzazione del Query Optimizer

MACRO: SCORCIATOIA SINTATTICA

lavorano a livello testuale senza comprendere realmente la struttura XML
XML integrato
modello di dati e query

- ESTENSIONE STANDARDIZZATA $\Rightarrow$ portabile

$\downarrow$
supporto STRUTTURALE e SEMANTICO

$\downarrow$
poco specifiche

20 Staging Area nel Data Warehouse → nel ETL

• AREA di MEMORIZZAZIONE TEMPORANEA

• permette (prima di CARICARE i dati) operazioni di

- PULIZIA
- DEDUPLICAZIONE
- CONTROLLO QUALITÀ
- PREPARAZIONE alle Trasformazioni

↳ lavorare sui dati senza accedere continuamente al sistema

posso ricavarmi una DELTA TABLE tra la staging e la tabella su cui caricare

tolgo duplicati ... ← vedo le differenze

21 Caratteristiche principali di un modello di dati multidimensionali, nei Data Warehouse

• **FATTI** = eventi di interesse delle analisi

↳ analisi dati come FATTI

MISURE NUMERICHE = su cui fare OPERAZIONI di aggregazione

← analizzabili su + DIMENSIONI

DIMENSIONI = descrivono il CONTESTO dei fatti

rappresentano PROSPETTIVE di ANALISI

tempo
luogo
...

Adattive
SemiAdattive
Non Adattive

organizzate in GERARCHIE = analisi a diversi LIVELLI di DETTAGLIO

operazioni di roll-up e drill-down ; + AGGREGATO ↔ + DETTAGLIATO

→ **GRANULARITÀ** : attuale livello di dettaglio del fatto

importante scelta progettuale

• influisce sulla PRECISIONE (delle analisi) e COSTI di MEMORIZZAZIONE e GESTIONE DATI

↓
CUBO DIMENSIONALE : ± DENSO x n combinazioni tra le dimensioni

↓
influenza su SPAZIO OCCUPATO e PRESTAZIONI delle Query

23 XQuery - funzione principale

= è un linguaggio dichiarativo x INTERROGARE dati XML
x TRASFORMARE

Strutturati

semi-strutturati

x consentire ACCESSO / SELEZIONE / RIORGANIZZAZIONE

- x ESTRARRE INFORMAZIONI
- x COSTRUIRE NUOVI FILE XML

• Supporta OPERAZIONI di INTERROGAZIONE ;

- FILTRAZIONE
- AGGREGAZIONE
- ORDINAMENTO

• basato su MODELLO di DATI a SEQUENCE = {NODI XML || VALORI ATOMICI}

INPUT → 1+ SEQUENZA → 1 SEQUENZA

⇒ meccanismo flessibile e espressivo x lavorare dati XML ⇒

x query complesse

x trasformazioni strutturate

24 Come viene usato XML in relazione a Dati Relazionali (SQL)

↳ come MECCANISMO di INTEGRAZIONE | RAPPRE | SCAMBIO

1 SQL/XML (publishing) $\xrightarrow{\text{IN}}$ Dati Relazionali $\xrightarrow{\text{XML}}$ XML

x INTEROPERABILITÀ

x SERVIZI WEB

Query SQL $\xrightarrow{\text{XML}}$ documenti XML

• strutture gerarchiche ad albero

⇒ non cambia il MODELLO DI RELAZIONE

2 Memorizzare XML doc come valori XML nativi in un DB relazionale

XML interrogabile con SQL/XML o XQuery

XML incapsulato in Dati Relazionali senza essere scomposto

3 Shredding = scomposizione doc XML $\left\{ \begin{array}{l} \square \\ \square \\ \square \end{array} \right\}$ in + tabelle relazionali x migliore rappresentazione

* + efficiente x query SQL

• perdita della struttura gerarchica originale

4 XML come interfaccia tra sistemi = linguaggio di INTERSCAMBIO

↳ con db relazionali

[PRODUCE o CONSUMA XML come messaggio di scambio tra sys]

* sys eterogenei

* nessun vincolo sul modello interno

25 Modello Vettoriale in IR introdotto x superare i limiti del modello booleano

1 RAPPRESENTAZIONE dei documenti e query a VETTORI

in uno SPAZIO MULTIDIMENSIONALE

• V DIMENSIONE $\equiv$ termine del vocabolario della collezione

↑
associato

↑ ottenuto dalle

↑ Fase di PRE-PROCESSING

PESO $\equiv$ importanza dei termini (nel doc | query) $\Rightarrow$ migliore QUALITA' DI RECUPERO

• Presenza o meno del termine

• FREQUENZA NEL DOCUMENTO


• FREQUENZA INVERSA DEL DOCUMENTO

- no ordinamento dei risultati
- visione binaria della rilevanza

2 Valutazione della rilevanza di un doc rispetto ad una Query

calcolata da SIMILARITA' [tra doc e query]

↓
similarita' coseno



valuta l'angolo

↳ Rendendo INDIP le misure dalle lung dei doc

$\Rightarrow$ due doc che condividono termini rilevanti con Query

hanno VETTORI VICINI nello spazio

3 Ranking del documento in base alle SIMILARITA' con la Query $\Rightarrow$ ORDINANDO i doc $\uparrow$

$\Rightarrow$ documenti migliori x quelle Query

ie Mod Vett. CLASSICO

PRO

* CORRISPONDENZE PARZIALI con Query e Doc

* RANKING NATURALE

* ESTENDIBILE facilmente x PESI / MISURE di SIMIL.

! indipendenze tra i termini $\Rightarrow$ non cattura RELAZIONI SEMANTICHE

! Rappre DIMENSIONI $\rightarrow$ COSTOSA x grandi collezioni

implementati nuovi modelli probabilistici

x approcci + avanzati

26 Perché usare Inverted Index in IR

INVERTED INDEX = struttura dati x recuperare VELOCEMENTE i doc che hanno un certo termine

termine $\rightarrow$ lista di documenti [invece del contrario]

composto da

$\rightarrow$ VOCABOLARIO $\neq$ tutti i termini indicizzati

$\rightarrow$ POSTING LIST $\neq$ termine

$\hookrightarrow$ ID docs in cui compare $\hookrightarrow$ frequenza del termine $\hookrightarrow$ posizione nel doc

1 COMPUTAZIONALMENTE EFFICIENTE il recupero dei doc

SENZA II: $\times$ rispondere a Query $\rightarrow$ scandire tutti i doc della collection $\rightarrow$ confrontandoli 1 alle volte

$\times$ accesso diretto alle liste di doc con i termini delle Query $\Rightarrow$ - doc da consultare

2 struttura dati di base x tutti i modelli IR

3 SCALABILITA' del modello a collezioni + grafi (Web)

indice può essere COMPRESSO / DISTRIBUITO su + nodi / AGGIORNATO INCREMENTALMENTE

$\times$ mantenendo OTTIMI TEMPI di RISPOSTA

4 efficace anche con Query complesse

5 Separa fase di INDICIZZAZIONE _{offline} da fase di QUERY PROCESSING _{online} $\times$ + Efficienze

27 Come funziona PageRank nel web IR = algoritmo di ranking

• web = grafo DIRETTO, nodi $\equiv$ pagine, archi $\equiv$ link

• pagina + importante quanto + è linkata da pagine importanti a loro volta

$\hookrightarrow$ IMPORTANZA dipende da link ENTRANTI e USCENTI

• basato sul Random Surfer: $\frac{1}{N}$ naviga seguendo un LINK USCENTE con $P = d (\sim 0.85)$
su una casuale pagina con $P = 1 - d$

$\Downarrow$

DAMP FACTOR

$\times$ garantire convergenza dell'algoritmo / gestire problemi ~ Pagine senza LINK ENTRANTI / USCENTI

• (di una pag) è definito come fun. RICORSIVA di PageRank di altre pp che la linkano

DISTRIBUZIONE STAZIONARIA CATENA di MARKOV $\leftarrow \left(\text{norm} \parallel n. \text{link uscenti} \parallel \right)$

< • è un SEGNALE QUERY-INDIPENDENT (offline) + QUERY-DEPENDENT (online) >

$\times$ migliorare la qualità dei risultati $\rightarrow$ favorendo pagine + autorevoli e centrali nella rete Web

28 Ruolo dell'Analisi Semantica nel Web IR

x MIGLIORARE PRECISIONE e QUALITÀ del ranking ← CATTURANDO il SIGNIFICATO dei TERMINI
modelli IR classici - recuperano informazioni con

↓ • OCCORRENZA dei TERMINI • FREQUENZA • DISTRIBUZIONE STATISTICA dei TERMINI

! Problemi di SINONIMI e POLISEMIA ⇒ Analisi Semantica cerca di risolverli

1 Rappresentazioni semantiche di doc e Query ≠ termini

↓
VETTORI SEMANTICI ← visti come → CONCETTI LATENTI
↳ misurare SIMILARITÀ SEMANTICA

2 comprensione della Query → INTERPRETARE l'INTENTO dell'UTENTE

⇒ gestire SINONIMI ⇒ migliorare matching con termini non esplicitati

3 Ranking più robusto: meno sensibile a variazioni superficiali del testo

SEGNALE SEMANTICO — combinato —> SEGNALE CONTENT-BASED

— integrato —> SEGNALE QUERY-DEPENDANT

* migliore RECALL, senza sacrificare la PRECISION

* Supporta ricerche complesse e su grandi collezioni ! alto COSTO COMPUTAZIONALE

! possibile perdita di interpretabilità

! Servono grandi quantità di dati x apprendere rappre. affidabili

⇒ Analisi Semantica USATA INSIEME a modelli tradizionali con metodi STATISTICI

29 Come funzionano le espressioni FLWOR, in XQuery = fasi con cui una Query è valutata

x INTERROGARE file XML ○ ○ tipo SELECT-FROM-WHERE di SQL

FOR x iterare su una sequenza di nodi → ∀ ciclo = genera ⇒ nuova associazione di vars

⇒ determina n soluzioni intermedie ci sono

[LET] associa una var - valore || sequenza di nodi ← senza nuovi cicli

x memorizzare soluzioni intermedie ⇒ migliore leggibilità e efficienza delle Query

WHERE x filtrare le associazioni di vars (prodotte dagli STEP PRIORI)

↳ Specificare CONDIZIONI BOOLEANE x ottenere quelle rilevanti ~ ALG. RELAZIONALE

ORDER BY x ordinare le sol in base a 1+ criteri

↓
tuple generate prima

RETURN x def la forma del risultato ⇒ COSTRUZIONE dell'OUTPUT XQuery

↳ Sequenza XML

30 Tokenizzazione in IR = fase di PRE-PROCESSING del testo

è necessario trasformare i doc testuali e elaborarli automaticamente

- un testo viene SPEZZETTATO con SEPARATORI
 - spazi
 - cambi riga
 - punteggiatura

a volte si scelgono CONVENZIONI

x URL x NUM x DATA x APOSTROFI' - - -

* sequenza ordinata di TOKEN $\equiv$ contenuto del doc in forma strutturata

→ influenza tutte le successive fasi di IR | INVERTED INDEX (per costruirlo)

↳ le scelte fatte si PROPAGANO nel sistema $\circ$ — $\circ$ intacca RECALL e PRECISION

• legata alle CARATTERISTICHE della LINGUA e del DOMINIO APPLICATIVO

x testi RUMOROSI come sul Web IR → diventa complesso tokenare

⇒ posso poi NORMALIZZARE

- lowercasing
- stemming = ridurre alla radice (TOLGO POSTFIX)
- lemmatizzazione = toglie inflessioni/variazioni mettendoli alla FORMA BASE

31 Come si misura la Rilevanza in un sistema di IR

Quanto un doc è utile RISPETTO ad una query e al bisogno di un utente ^{info}

⇒ RILEVANZA è STIMATA, non è conosciuta ESATTAMENTE



con FUNZIONI di RANKING: doc → punteggio = quanto il CONTENUTO doc

Mod. Classici • usano STATISTICHE sui TERMINI

Mod. Moderni • combinano + segnali — matching termini / similarità
— autorevolezza delle pag = PageRank

? STIMANO BENE? → GIUDIZI di RILEVANZA (manualmente || implicitamente)
x confronto dei risultati con un "Gold Standard"

GOLD STANDARD

> misurata a liv. sistema con METRICHE STANDARD

PRECISION: % doc RILEVANTI che sono RILEVANTI → MISURA la QUALITÀ dei RISULTATI

RECALL: % doc RILEVANTI TOTALI che sono stati RECUPERATI → MISURA la COMPLETEZZA

F-MEASURE MEDIA ARMONICA tra PRECISION e RECALL = $\frac{2PR}{P+R}$

{PRECISION|RECALL}@k PIR dei primi k risultati → importantissimo in Web IR

32 Differenza tra Modelli Booleani e Modelli Probabilistici in IR

Modello Booleano = Rispetta la Query $\checkmark_x \Rightarrow$ fa un MATCHING ESATTO con la Query
 $\Rightarrow$ NON PRODUCE UN RANKING, hanno tutti lo stesso peso se rispettano la Q

OPERATORI LOGICI
piccole variazioni CAMBIANO I RISULTATI

Modello Probabilistico = Stima la PROBABILITA' che un doc e' RILEVANTE x una Query

$\Rightarrow$ RILEVANZA GRADUALE $\Rightarrow$ ho un RANKING ROBUSTO

• usa INFO STATISTICHE sui termini x PESARE i doc

* efficace nel catturare Rilevanza $\rightarrow$ risultati ordinati

ES
~ BM25 #1 implementato

- FREQUENZA dei TERMINI
- FREQUENZA INVERSA del doc
- LUNGHEZZA del doc

33 Schemi a Stella e a Fiocco di Neve in Data Warehouse

x organizzare dati con modello multidimensionale

x analisi OLAP efficienti

= 2 modalita' di TRADUZIONE del modello multidim in uno SCHEMA RELAZIONALE

Schema a STELLA ★ + usato

FACT-TABLE centrale $\begin{cases} \square \\ \square \end{cases}$ TABELLE di DIMENSIONE
• MISURE
• CHIAVI ESTERNE verso le dim
• denormalizzate
• ATTRIBUTI SIGNIFICATIVI

- SEMPLICE e INTUITIVO (STRUTTORA)
- POCHI JOIN nelle Query $\rightarrow$ semplici
- BUONE PRESTAZIONI x OLAP
- DATI RIDONDANTI nelle dim
- * ottimo quando non si hanno problemi di SPAZIO DI ARCHIVIAZIONE

normalizzato

Schema a FIOCCO DI NEVE ❄️

FACT-TABLE centrale $\begin{cases} \swarrow \\ \searrow \end{cases}$ Tabelle di dimensione
< NORMALIZZATE >
in + tabelle connesse

- DATI - RIDONDANTI
- STRUTTURA + COMPLESSA
- + JOIN nelle Query $\Rightarrow$ + complesse
- Query + COSTOSE

ottimo x DIMENSIONI grandi e complesse

x - RIDONDANZA $\Rightarrow$ OCCUPA - SPAZIO

x difficile MANUTENZIONE delle gerarchie tra dim

34 Gestione Dati Non Strutturati in IR (~ documenti testuali | audio | immagini)

↓
non seguono uno schema rigido come tabelle relazionali

x esplorarli in modo efficiente → TRASFORMATI secondo un processo specifico;

1 RACCOLTA e RAPPRESENTAZIONE • sono UNITÀ TESTUALI INDIPENDENTI e Collezione con METADATI

2 PRE-PROCESSING

- | | | |
|------------------------------------|-------------------|---|
| • Tokenizzazione | • Stemming | } ottengo un testo in
forma COMPATTA e + INFORMATIVA |
| • Normalizzazione | • Lemmatizzazione | |
| • Eliminazione di parole frequenti | | |

3 INDICIZZAZIONE costruzione e composizione dell' INVERTED INDEX; termine → lista doc

- frequenza dei termini
 - posizione nel doc
 - peso
- * accesso rapido ai doc * scalabile su grandi collezioni

4 RANKING e RAPPRESENTAZIONE

Scelta del modello BOOLEANO | VETTORIALE | PROBABILISTICO → Ranking? ⇒ ordinamento

5 GESTIONE AMBIGUITÀ date dalla non struttura ⇒ SEMANTICA IMPLICITA

- cercare RILEVANZA da SIMILARITÀ | FEEDBACK UTENTE | ARRICCHIMENTO SEMANTICO

35 Varianza e Deviazione Standard in Statistica Descrittiva; MISURE fond. di DISPERSIONE

STATISTICA DESCRITTIVA = DESCRIVERE | RIASSUMERE | RAPPRESENTARE un insieme di dati
non traendo CONCLUSIONI generali o fare PREVISIONI oltre i dati osservati
→ la SALUTE del dataset

x quantificare quanto i dati si discostano dal valore medio

VARIANZA = MEDIA dei QUADRATI degli SCARTI della MEDIA ⇒ quanto si discostano i dati

x misurare VARIABILITÀ COMPLESSIVA del fenomeno

! unità di misura al quadrato² ⇒ poco INTERPRETABILE direttamente

DEVIAZIONE STANDARD = $\sqrt{\text{VARIANZA}}$ con stessa unità di misura dei dati ⇒ + INTERPRETABILE

Sono importanti perché:

4 Sono alla base di

- | | |
|---|--------------------------|
| 1 completano la descr. della MEDIA | • NORMALIZZAZIONE |
| 2 permettono CONFRONTO tra DISTRIBUZIONI | • Analisi Esplorativa |
| 3 aiutano a trovare DIFFERENZE e ANOMALIE | • Metodi Statistici e ML |

36 Misure di Centralità in Statistica

sono INDICI STATISTICI che individuano un valore che RAPPRE. la DISTRIBUZIONE intorno al quale i dati si CONCENTRANO

x riassumere grandi quantità di dati in un unico VALORE

x confrontare tra + DISTRIBUZIONI

x 1^a descrizione del fenomeno osservato

x analisi esplorativa dei dati (fondamentale)

MEDIA ARITMETICA = $\frac{\text{somma di tutti i valori}}{\text{num totale di valori}}$ è il tipico valore della distribuzione
! sensibile a dati ANOMALI

MEDIANA = valore centrale di dati ordinati (cresc || decresc)

divide la DISTRIBUZIONE in 2 parti uguali → ottima x DATI ASIMMETRICI

* non influenzata da DATI ANOMALI

MODA = valore che compare + FREQUENTEMENTE in dati ordinati

x identificare i valori + comuni nella distribuzione

ottima x dare un'idea sull'andamento generale dei dati

37 Covarianza e Correlazione in Statistica

= descrivono il LEGAME tra 2 vars

COVARIANZA = misura la VARIABILITA' CONGIUNTA di 2 vars RISPETTO alle loro MEDIE

↳ POSITIVA entrambe sono SOPRA || SOTTO la MEDIA

↳ NEGATIVA 1 SOPRA e 1 SOTTO la MEDIA

↳ CIRCA ZERO Non c'è Relazione Lineare

! dipende dall'UNITA' di MISURA delle vars

usato come misura intermedia

! VAL NUMERICO difficile da INTERPRETARE

CORRELAZIONE = COVARIANZA normalizzata; misura DIREZIONE e INTENSITA' della Rel. Lineare

= +1 rel. Lineare PERFETTA = 0 ≠ rel. Lineare

= -1 rel. Lineare NEGATIVA PERFETTA

* adimensionale ⇒ No UNITA' DI MISURA → ho misura CONFRONTABILE

38 Query Espansive in IR

TECNICHE x migliorare il RECUPERO di doc ^{RILEVANTI} → ESPANDENDO la Query con + TERMINI
x ridurre il MISMATCH LESSICALE tra doc e Query SEMANTICAM. CORRELATI

1 ESPANSIONE da RISORSE ESTERNE: THESAURUS | DIZIONARI | ONTOLOGIE | Rd. SEMANTICHE
automobile → auto | macchina | autoveicolo

2 FEEDBACK di RILEVANZA dell'utente! → su TERMINI ESTRATTI dal sistema
↳ Query espansa con termini SCELTI

3 FEEDBACK di PSEUDO-RILEVANZA: il SISTEMA ASSUME che i primi k doc Recuperati siano RILEVANTI
⇒ ESTRAE i termini + INFORMATIVI ⇒ espansione automatica
+ usata ⇒ NON RICHIEDE INTERVENTO UMANO ⇒ ! può aggiungere RUMORE se non sono RILEVANTI

* RECALL + ^{alta} ~~precisa~~

⇒ necessario bilanciamento tra Termini ORIGINALI / AGGIUNTI
+ Rilevanti — Rilev.

* PRECISION può essere ridotta

39 Normalizzazione in IR = fase di PRE-PROCESSING

x RIDURRE le VARIANTI SUPERFICIALI dei TERMINI ⇒ parole = || ≈ con stessa semantica

• composto da # TRASFORMAZIONI

trattate in modo EQUIVALENTE

lowercasing: togliere simboli e punteggiatura gestione accenti / special char
uniformazione di forme equivalenti

1 - MISMATCH LESSICALE

2 RECALL MIGLIORE ↑

3 RANKING + affidabile e con pesi più precisi

4 Riduce lo SPAZIO dei termini → INVERTED INDEX + compatto ⇒ SISTEMA + EFFICIENTE

5 A volte serve fare compromessi tra MATCHING ROBUSTO e SEMANTICA precisa

↳ ! PERDERE INFO

↳ ! introdurre AMBIGUITA'

40 Analisi dei Collegamenti in Web IR

27 + HITS (Hyperlinked - Induced Topic Search) $\Rightarrow$ RILEVANZA TEMATICA

$\downarrow$
CALCOLA 2 PUNTEGGI

authority = quanto una pagina è considerata AUTOREVOLE

hub = quanto una pagina è buona nel puntare a pagine autorevoli

* **query-dependent** = si costruisce un sottografo intorno ai risultati pertinenti

$\downarrow$

* Analisi dei Collegamenti usata ANCHE (oltre al Ranking puro)

x GUIDARE la SCANSIONE del Web = quali pag CRAWLARE prima

x TROVARE pagine CORRELATE o DUPLICATE

+ (x CLASSIFICARE pagine per AUTORITÀ | RILEVANZA TEMATICA)

x MIGLIORARE METRICHE di RELAZIONE tra doc nei Sistemi IR

$\uparrow$

41 Database orientati al soggetto ^{CARATTERISTICA} (nel Data Warehouse)

= DATI NON SONO ORGANIZZATI x processi operativi

ma $\rightarrow$ SONO ORGANIZZATI x temi di analisi rilevanti x il business

MISURE
DIMENSIONI $\leftarrow$ FATTI

$\nwarrow$ DA ORIGINE $\rightarrow$ SOGGETTI $\rightarrow$ Di cosa analizziamo?

$\downarrow$
guida la progettazione del Data Warehouse

- eventi misurabili x l'analisi nell'area del
- nella fact-table

concretizza

Cosa Misuriamo in MODO OPERATIVO

42 Gestione Dati variabili nel Tempo nel Data Warehouse

x CONSERVARE LO STORICO delle info x analisi temporali | tendenza

NON VOLATILITÀ = una volta caricati, i dati NON VENGONO AGGIORNATI | CANCELLATI

$\rightarrow$ ma SOLO: INSERITI

TIME VARIANCE = ogni dato è ASSOCIATO a un RIFERIMENTO TEMPORALE

$\Rightarrow$ x memorizzarle su lunghi periodi $\Rightarrow$ TEMPO come DIMENSIONE ESPlicita

43 Ruolo XML Type in Oracle DB

= tipo di dati x GESTIRE XML nel database ⇒ posso usare Query SQL
MEMORIZZARE
INTERROGARE
x dati XML

2 tipi di implementazioni → in base SPECIFICHE utente | PRESTAZIONI

LOB Large Object = tipo una stringa semplice

STRUCTURED STORAGE = DBMS costruisce automaticamente una TABLE seguendo XML Schema

44 Come integrare XML in un Database Relazionale

x gestire DATI SEMI-STRUTTURATI in DBMS x non PERDERE ^{XML} flessibilità di XML
x " " capacità di interrogazione SQL

• MEMORIZZATO con tipo di DATO AD-HOC x mantenere Struttura gerarchica XML
! ha IMPATTO sulle PRESTAZIONI

• INTERROGARE XML direttamente dal DBMS → navigandone la sua struttura
↳ anche con Query SQL e XPath combinate

45 Perché usare Deep Learning in IR

x ovviare ai LIMITI STRUTTURALI dei modelli classici di IR

COMPRENDERE il SIGNIFICATO

GESTIRE SINONIMI / POLI SEMIA / CONTESTO

< MACHINE Learning IMPARA dai DATI cosa rende un doc RILEVANTE >

1 APPRENDIMENTO della RILEVANZA [↓]
+ fedele

↑

- assegnano PESI alle FEATURE

- modellano INTERAZIONI NON LINEARI tra segnali

2 MISMATCH LESSICALE tra Query e Doc x RAPPRE VICINE di termini simili x semantica

↳ RECUPERO DOC CONCETTUALMENTE RILEVANTI (senza MATCHING ESPlicito di termini)

LEARNING to RANK: COSTRUIRE UN TRAINING SET C VETTORI di FEATURE ^{ass.} RELEVANCE JUDGMENT

quel doc è rilevante per la Query?

46 Query Suggestion in IR

= {TECNICHE} x PROPORRE ALTERNATIVE | ESTENSIONI delle Query Cor dell' $\mathcal{R}$
x MIGLIORARE L'EFFICACIA | RIDURRE lo sforzo di formulazione delle Query

Evitare che

- x Query SPESSE BREVI | MAL SPECIFICATE | CON ERRORI
- x termini AMBIGUI

AUTO-COMPLETAMENTO Ridurre il tempo e POPOLARITÀ | PROBABILITÀ di completamento

CORREZIONE GRAMMATICALE migliorare MATCHING

RIFORMULAZIONE e PERFEZIONAMENTO SPECIFICARE | GENERALIZZARE | LATERALIZZARE

SINONIMI o CORRELAZIONI ↑ aumentare RECALL

SUGGERIMENTI dallo storico "modellare un percorso di ricerca"

Da dove arrivano i dati (SUGGERIMENTI)

- Query LOG e COMPORTAMENTO $\mathcal{R}$
- Collezione di Doc → analisi dei termini TF-IDF / BM25
→ termini espansivi
- Dizionari — x disambiguare e sinonimi
- ML

47 Cosa si può fare con il Data Mining applicato ai Social networks

processo di ANALISI di ELABORAZIONE di grandi quantità di dati x estrarre PATTERN / INFO

SENTIMENT ANALYSIS - IDENTIFICA / CLASSIFICA il sentimento espresso dagli utenti tramite testo

↓
POPOLARITÀ EMOTIVA | INTENSITÀ o TIPO di EMOZIONE

x compr. l'OPINIONE PUBBLICA su certi argomenti

SEGMENTAZIONE UTENTI INTERESSI | ^{caratt} DEMOGRAFICHE | COMPORTAMENTI

RILEVARE TENDENZE | EVENTI | FEEDBACK

ANALISI delle RETI SOCIALI identificare INFLUENCER | COMUNITÀ | GRUPPI di INTERESSE

RILEV:

PREVISIONI del COMPORTAMENTO $\rightarrow$ Probabilità d'ACQUISTO | EVENTI | VIAGGI ...

$\Rightarrow$ con obiettivo x Analisi di Mercato / Monitoraggio dell'opinione pubblica

$\Rightarrow$ TRAMITE estrazione di sottogruppi con Clustering